

POTANSİYEL OLARAK TEHLİKELİ ASTEROİDLERİN MAKİNE ÖĞRENMESİ TABANLI SINIFLANDIRILMASI: SINIF DENGESİZLİĞİ ALTINDA RECALL ODAKLI BİR YAKLAŞIM

Adı SOYADI^{1*}, Adı SOYADI² (Dergi editörlüğü tarafından basım aşamasında yazılacaktır.)

¹ Yazar 1 Adresi, ORCID No : <https://orcid.org/>

² Yazar 2 Adresi, ORCID No : <https://orcid.org/>

Anahtar Kelimeler	Öz
Tehlikeli Asteroid Sınıflandırması Makine Öğrenmesi Random Forest XGBoost Sınıf Dengesizliği	<i>Yere Yakın Asteroidlerin (NEA) çarpma potansiyeli, modern uzay gözleminin en yüksek etkili ve en güçlü öngörülen risklerinden birini oluşturmaktadır. Geleneksel kural tabanlı tehlike sınıflandırması, mutlak parlaklık ve minimum yörünge kesişim mesafesi gibi parametrelerin doğrusal olmayan etkileşimlerini yeterince modelleyememektedir. Bu çalışmada, NASA Jet Propulsion Laboratory'nin Near-Earth Object Web Service (NeoWs) altyapısından türetilen ve Kaggle üzerinden erişilebilen NASA: Asteroids Classification veri kümesi kullanılarak bir asteroidin Potansiyel Olarak Tehlikeli Asteroid (PHA) olup olmadığını öngören risk-duyarlı bir makine öğrenmesi çerçevesi önerilmektedir. Veri kümesi 4.687 gözlem ve 40 öznitelik içermekte; tehlikeli sınıf yalnızca %16,1 oranında temsil edilmektedir. Bu belirgin dengesizlik, doğruluk metriğini yanıltıcı kılmakta ve en kritik hata türü olan False Negative oranının azaltılmasını birincil hedef hâline getirmektedir. Önerilen çerçevede sızıntı riski taşıyan değişkenlerin kontrollü biçimde ele alınması, eşdeğer birim tekrarlarının elenmesi ve sınıf dengesizliğinin SMOTE ile class_weight stratejilerinin karşılaştırmalı uygulanmasıyla giderilmesi öngörülmektedir. Modelleme katmanında baseline olarak Lojistik Regresyon, ana modeller olarak Random Forest ve XGBoost kullanılmış; hiperparametre ayarı GridSearchCV ile beş katlı stratified k-fold çapraz doğrulama altında recall ve F1 odaklı bileşik bir kriterle gerçekleştirilmiştir. Değerlendirme; recall, F1-skoru, ROC-AUC, PR-AUC ve karışıklık matrisi üzerinden False Negative analiziyle yapılandırılmıştır. Beklenen çıktı, doğruluk yerine pozitif sınıfın korunmasını önceliklendiren, açıklanabilir ve metodolojik tutarlılığı yüksek bir tehlikeli asteroid sınıflandırma çerçevesinin elde edilmesidir.</i>

MACHINE LEARNING-BASED CLASSIFICATION OF POTENTIALLY HAZARDOUS ASTEROIDS: A RECALL-ORIENTED APPROACH UNDER CLASS IMBALANCE

Keywords	Abstract
Hazardous Asteroid Classification Machine Learning Random Forest XGBoost Class Imbalance	<i>The impact potential of Near-Earth Asteroids (NEA) constitutes one of the most consequential yet least predictable risks in modern space observation. Conventional rule-based hazard classification, grounded in thresholds over absolute magnitude and minimum orbit intersection distance, fails to capture the nonlinear interactions among orbital and physical parameters. This study proposes a risk-sensitive machine learning framework for classifying whether an asteroid qualifies as a Potentially Hazardous Asteroid (PHA), using the NASA: Asteroids Classification dataset derived from NASA JPL's Near-Earth Object Web Service (NeoWs) and distributed through Kaggle. The dataset comprises 4,687 observations and 40 features, with the hazardous class accounting for only 16.1% of the records. This pronounced imbalance renders accuracy a misleading indicator and elevates the minimization of False Negatives to the primary optimization objective. The proposed pipeline addresses leakage-prone features, eliminates redundant unit-equivalent columns, and mitigates class imbalance through a comparative application of SMOTE and class-weighting strategies. Logistic Regression is employed as a baseline, while Random Forest and XGBoost serve as the principal models, selected for their robustness on tabular, nonlinear feature spaces. Hyperparameters are tuned via GridSearchCV under five-fold stratified cross-validation, optimizing a composite criterion centered on recall and F1-score. Evaluation integrates recall, F1-score, ROC-AUC, PR-AUC, and confusion-matrix-based False Negative analysis. The expected outcome is an interpretable and methodologically consistent classification framework that prioritizes the preservation of the positive class over inflated accuracy figures.</i>



Bu eser, Creative Commons Attribution License (<http://creativecommons.org/licenses/by/4.0/>) hükümlerine göre açık erişimli bir makaledir.

This is an open access article under the terms of the Creative Commons Attribution License (<http://creativecommons.org/licenses/by/4.0/>).

Araştırma Makalesi

Başvuru Tarihi : GG.AA.YYYY

Kabul Tarihi : GG.AA.YYYY

Research Article

Submission Date : GG.AA.YYYY

Accepted Date : GG.AA.YYYY

* Sorumlu yazar: eposta@aaa.edu.tr
<https://doi.org/10.xxxxx/ogummf.10xxxxx>

1. Giriş

Uzay tabanlı tehditler, etki olasılığı düşük fakat sonuçları yıkıcı olabilen bir risk kategorisini temsil etmekte ve bu nedenle modern astronomik gözlemin temel önceliklerinden biri hâline gelmektedir. Yere Yakın Asteroidler (Near-Earth Asteroids, NEA), Dünya yörüngesine olan yakınlıkları ve yörünge dinamiklerinin pertürbasyonlara karşı duyarlılığı nedeniyle bu risk sınıfı içinde özel bir konum işgal etmektedir. NASA Jet Propulsion Laboratory (JPL) ve Avrupa Uzay Ajansı (ESA) gibi kurumların yürüttüğü gözlem programlarının ürettiği veri hacmi, manuel risk değerlendirmesinin sınırlarını aşmış; bu durum, otomatik karar destek sistemlerini bir tercih meselesinden operasyonel bir zorunluluğa dönüştürmüştür.

Bu çerçeve içinde tanımlanan spesifik problem, bir asteroidin Potansiyel Olarak Tehlikeli Asteroid (Potentially Hazardous Asteroid, PHA) olup olmadığını belirleyen ikili sınıflandırma görevidir. Geleneksel yaklaşım, mutlak parlaklık ve minimum yörünge kesişim mesafesi (MOID) üzerine kurulu eşik tabanlı kurallara dayanmakta; ancak bu deterministik tanım, yörünge parametreleri arasındaki yüksek dereceli ve doğrusal olmayan etkileşimleri ihmal etmektedir. Makine öğrenmesi yöntemleri, bu örüntüleri veriden öğrenebilme kapasiteleri sayesinde mevcut kuralı tamamlayıcı ve geleceğe yönelik genelleme sağlayan bir çözüm hattı sunmaktadır.

Problemin kritikliği, hata türlerinin asimetrik maliyetinden ileri gelmektedir. Tehlikesiz bir asteroidin yanlışlıkla tehlikeli sınıflandırılması (False Positive) yalnızca ek gözlem kaynağı tüketirken, gerçek bir tehlikeli cismin gözden kaçırılması (False Negative) tafisi mümkün olmayan sonuçlara yol açabilmektedir. Bu asimetri, başarı tanımının yeniden çerçevelenmesini gerektirmekte; accuracy yerine pozitif sınıfın korunmasını ölçen recall ve False Negative sayısı, anlamlı birincil metrikler olarak öne çıkmaktadır. Dolayısıyla problem, standart bir sınıflandırma görevinden risk-duyarlı bir karar problemine dönüşmektedir.

Bu çalışmanın amacı, NASA NeoWs kaynaklı tablosal asteroid verisi üzerinde, sınıf dengesizliği koşullarında False Negative oranını minimize etmeyi birincil hedef olarak benimseyen bir makine öğrenmesi çerçevesi geliştirmektir. Çalışmanın temel katkıları üç eksenle özetlenebilir: birincisi, başarı tanımının doğruluktan recall odaklı bir kompozit kritere taşınması; ikincisi,

PHA tanımının doğrudan girdileri olan değişkenlerin sızıntı riski açısından kontrollü biçimde ele alınması; üçüncüsü ise tablosal veri yapısına uygun ağaç tabanlı topluluk modellerinin (Random Forest, XGBoost) doğrusal bir baseline ile karşılaştırılarak metodolojik olarak tutarlı bir model seçim çerçevesinin sunulmasıdır.

2. Bilimsel Yazın Taraması

Tehlikeli asteroid sınıflandırması, son beş yılda hem metodolojik çeşitlenme hem de paradigma çatalanması yaşamış görece genç bir araştırma alanıdır. Literatürün sergilediği eğilim, klasik istatistiksel sınıflandırıcılardan ağaç tabanlı topluluk yöntemlerine, oradan da olasılıksal modelleme, açıklanabilir yapay zekâ ve nihayet kuantum hesaplama gibi sınır paradigmalara doğru bir genişleme biçiminde özetlenebilir. Bu kesit, hem yöntemlerin çeşitliliği hem de aynı problemde elde edilen başarı oranlarının olağandışı yüksekliği nedeniyle eleştirel bir okumayı zorunlu kılmaktadır. Bu bölümde, alanı temsil eden sekiz çalışma kronolojik değil, metodolojik benzerlik eksenine göre gruplanarak yöntem, katkı ve sınırlılık çerçevesinde analiz edilmekte; ardından bu çalışmaların bir arada okunmasından doğan üç yapısal araştırma boşluğu tartışılmaktadır.

İlk grupta, klasik denetimli öğrenme yaklaşımlarını tablosal asteroid verisine uygulayan karşılaştırmalı çalışmalar yer almaktadır. Bu grubun temsilcilerinden ilki, 2025 yılında yayımlanan “Comparative Analysis of Machine Learning Models for Hazardous Asteroid Classification” başlıklı çalışmadır. Söz konusu çalışma, AdaBoost, Random Forest, Support Vector Machine, Naive Bayes, K-Nearest Neighbors ve CatBoost sınıflandırıcılarını ortak bir veri kümesi üzerinde kıyaslamış; ön işleme aşamasında SMOTE ile sentetik aşırı örnekleme ve K-select tabanlı özellik seçimi kullanmıştır. Çalışmanın temel katkısı, sınıf dengesizliğinin model performansı üzerindeki etkisini sistematik biçimde nicelleştirmiş olmasıdır; ancak Minimum Orbit Intersection Distance (MOID) ve mutlak parlaklık (H) gibi PHA tanımının doğrudan bileşeni olan değişkenlerin eğitime aynen dâhil edilmesi, raporlanan yüksek başarı oranlarının gerçek bir genelleme yansıtip yansıtmadığını şüpheli kılmaktadır. Aynı grubun bir başka temsilcisi olan “Classifying Hazardous and Non-Hazardous Asteroids Using Machine Learning” (2022) çalışması, NASA NeoWs verisi üzerinde Lojistik Regresyon, SVM, Random Forest ve XGBoost modellerini GridSearchCV



Bu eser, Creative Commons Attribution License (<http://creativecommons.org/licenses/by/4.0/>) hükümlerine göre açık erişimli bir makaledir.

This is an open access article under the terms of the Creative Commons Attribution License (<http://creativecommons.org/licenses/by/4.0/>).

ile optimize ederek karşılaştırmıştır. Çalışma, XGBoost'un doğrusal modellere kıyasla belirgin üstünlüğünü ortaya koymasıyla literatürdeki ensemble eğilimini güçlendirmektedir; ne var ki raporlanan recall değerlerinin sınırlı kalması, modelin doğruluk skorunu büyük ölçüde çoğunluk sınıfı üzerinden ürettiğine, dolayısıyla tehlikeli sınıfı kaçırma riskinin metodolojik düzeyde çözülemediğine işaret etmektedir. Bu iki çalışma birlikte değerlendirildiğinde, klasik denetimli öğrenme paradigmasının asteroid sınıflandırmasında kararlı bir performans tabanı sağladığı; ancak hem değerlendirme metriği hem de özellik mühendisliği düzeyinde önemli zafiyetler taşıdığı görülmektedir.

İkinci grup, tablosal verinin ötesine geçerek asteroid sınıflandırmasını farklı veri tipleri ve daha geniş ölçeklerle ilişkilendiren çalışmalardan oluşmaktadır. "Machine Learning Techniques for Classifying Dangerous Asteroids" (2023) başlıklı çalışma, yaklaşık 90.836 asteroid içeren büyük bir veri kümesi üzerinde Extra Trees, Random Forest, LightGBM, Gradient Boosting ve AdaBoost gibi ağaç tabanlı topluluk yöntemlerinin baskın performansını ortaya koymuştur. Çalışmanın güçlü yönü, ölçek artışının ensemble modellerinin yapısal avantajlarını nasıl pekiştirdiğini göstermesidir; ancak değerlendirme çerçevesinin neredeyse tamamen doğruluk metriği etrafında kurgulanması, dengesiz veri koşullarında gerçek başarımın gizlenmesi sorununu yeniden üretmektedir. Aynı grupta yer alan ancak farklı bir veri modalitesini kullanan "Assessment of Asteroid Classification Using Deep Convolutional Neural Networks" (2023) çalışması, InceptionV3, Xception, InceptionResNetV2 ve ResNet152V2 gibi derin evrişimli mimarilerle teleskop görüntülerinden asteroid-asteroid olmayan ayrımı yapmıştır. Transfer öğrenmenin gücünü astronomik görüntüleme bağlamında somutlaştıran bu yaklaşım, görüntü tabanlı tespit problemleri için değerlidir; ancak girdisi yörünge ve fiziksel parametrelerden oluşan tablosal bir sınıflandırma probleminde, derin CNN mimarilerinin doğrudan uygulanabilirliği bulunmadığı gibi, problemi olduğundan daha karmaşık bir hesaplama çerçevesine taşıyarak aşırı mühendislik niteliği kazanmaktadır. Bu iki çalışmanın karşılaştırılması, veri tipinin model seçimini doğrudan belirlediğini ve tablosal asteroid verilerinde derin öğrenmeye yönelmenin metodolojik bir kazanım sağlamadığını net biçimde ortaya koymaktadır.

Üçüncü grup, statik sınıflandırma paradigmasını aşmaya yönelik ve probleme zamansal ya da olasılıksal bir boyut ekleyen çalışmaları kapsamaktadır. "Temporal Trends in Asteroid Behaviour and Hazard Classification" (2024) başlıklı çalışma, Decision Tree, Random Forest, AdaBoost ve Gradient Boosting modellerini Mercury N-body integrator simülatörüyle birleştirerek yörünge evriminin tehlike sınıfı üzerindeki etkisini incelemiştir. Bu yaklaşım, asteroid tehlikesinin sabit bir özellik olmadığını, yörünge

dinamiklerinin uzun vadeli pertürbasyonlarına bağlı olarak değiştiğini görünür kılmaları bakımından kavramsal olarak özgündür; ancak N-body simülasyonunun yüksek hesaplama maliyeti ve özel altyapı gereksinimi, yöntemin operasyonel bir karar destek sistemi olarak ölçeklenebilirliğini ciddi biçimde sınırlandırmaktadır. Aynı grupta yer alan "Near-Earth Asteroids Classification Using Natural Gradient Boosting (NGBoost)" (2024) çalışması ise probleme olasılıksal bir çerçeveye yaklaşmakta; ikili etiket yerine bir risk olasılığı üretmek SHAP ve permütasyon önemi gibi açıklanabilirlik araçlarını sürece dâhil etmektedir. NGBoost'un sağladığı dağılımsal çıktı, risk önceliklendirmesi gibi karar süreçleri için klasik 0/1 etiketinden daha bilgilendiricidir; bununla birlikte, aynı tablosal veri kümeleri üzerinde elde edilen olağandışı yüksek doğruluk değerleri, modelin yörünge dinamiklerini öğrenmek yerine veri setine gömülü etiketleme kuralını yeniden ürettiği şüphesini güçlendirmektedir. Bu iki çalışma, alanın saf etiketleme arayışından risk-duyarlı ve zamansal olarak farkındalıklı bir modellemeye doğru kaydığını göstermekle birlikte, söz konusu kayışın henüz standart bir metodolojiye dönüşmediğini de ortaya koymaktadır.

Dördüncü grup, problemi sınır paradigmalara taşıyan ve daha çok kavramsal araştırma niteliği taşıyan çalışmalardan oluşmaktadır. "Classification of Potentially Hazardous Asteroids Using Supervised Quantum Machine Learning" (2023) başlıklı çalışma, Variational Quantum Classifier (VQC) ve Pegasos Quantum Support Vector Classifier (PegasosQSVC) mimarilerini kuantum öznelik haritalama ile birlikte kullanarak PHA sınıflandırmasını kuantum hesaplama düzleminde ele almıştır. Çalışma, kuantum makine öğrenmesinin astronomik sınıflandırma görevlerine uygulanabilirliğini gösteren öncül bir kanıt sunmaktadır; ancak güncel NISQ (Noisy Intermediate-Scale Quantum) donanımının ölçek ve gürültü kısıtları, yöntemi uygulanabilir bir çözümden çok teorik bir araştırma motivasyonu konumuna yerleştirmektedir. Bu grupla yapısal olarak ilişkilendirilebilecek bir başka çalışma, "Big Data Classification Using Heterogeneous Ensemble Classifiers in Apache Spark with ISVM-RFE" (2021) başlıklı araştırmadır. Doğrudan asteroid verisine özel olmamakla birlikte, Apache Spark ve MapReduce altyapısı üzerinde heterojen topluluk sınıflandırıcılarını ISVM-RFE (Incremental SVM tabanlı Recursive Feature Elimination) ile birleştirerek büyük ölçekli, dengesiz veri kümelerinde ölçeklenebilir bir sınıflandırma mimarisi önermektedir. Bu çalışma, asteroid sınıflandırmasının ölçek arttıkça hangi yapısal mimari kararlara ihtiyaç duyacağına dair önemli bir referans çerçevesi sunmaktadır; ancak veri kümesi ve problem alanı farklılığı nedeniyle bulgularının doğrudan transferi sınırlıdır.

Bu sekiz çalışmanın bütünsel okuması, alandaki metodolojik tercihler arasındaki örtük hiyerarşiyi netleştirmektedir. Ağaç tabanlı topluluk yöntemleri, tablosal asteroid verisinde hem doğrusal modellerden hem de derin sinir ağı tabanlı yaklaşımlardan tutarlı biçimde daha yüksek başarı sağlamaktadır. Bu üstünlüğün temel nedeni, yörünge ve fiziksel parametreler arasındaki yüksek dereceli, doğrusal olmayan etkileşimlerin söz konusu modellerin öğrenme yapısına doğal biçimde uymasındır. NGBoost gibi olasılıksal modeller, ikili etiket yerine bir risk dağılımı üreterek karar destek değerini artırmakta; SHAP ve permütasyon önemi gibi açıklanabilirlik araçları, kara kutu eleştirisini hafifletmektedir. Buna karşılık derin CNN ve kuantum makine öğrenmesi yaklaşımları, paradigma yeniliği bakımından dikkat çekici olmakla birlikte, ya veri tipi uyumsuzluğu ya da donanımsal kısıtlar nedeniyle problemin pratik gereksinimleriyle örtüşmemekte ve mevcut tablosal sınıflandırma probleminde belirgin bir kazanım sağlamamaktadır.

Ancak bu literatür panoraması, üç yapısal araştırma boşluğunu belirgin biçimde görünür kılmaktadır. Birinci boşluk, sınıf dengesizliği probleminin yüzeysel ele alınmasıyla ilgilidir. İncelenen çalışmaların çoğunda dengesizlik müdahalesi SMOTE veya rastgele örnekleme ile sınırlı tutulmakta; bu müdahalenin hangi modelle, hangi veri bölünmesi protokolü altında ve hangi metrik altında değerlendirildiği yeterince tartışılmamaktadır. Özellikle SMOTE'un sentetik örneklerinin test kümesine sızdırılmadan uygulanıp uygulanmadığı, raporlanan başarı oranlarının güvenilirliğini doğrudan etkileyen, ancak literatürde çoğu zaman örtük bırakılan bir konudur. İkinci boşluk, başarı ölçütlerinin yapısal olarak uygunsuz seçimidir. Asteroid sınıflandırması, hatalı pozitiflerin yalnızca ek gözlem maliyeti doğurduğu, hatalı negatiflerin ise telafisi mümkün olmayan sonuçlara yol açtığı asimetrik bir karar problemidir; buna rağmen literatürün büyük çoğunluğu doğruluk odaklı bir değerlendirme çerçevesi benimsemekte, recall ve False Negative sayısı yeterince ön plana çıkarılmamaktadır. Bu durum, raporlanan başarı oranlarının operasyonel güvenliğe ne ölçüde tercüme edilebileceğini belirsizleştirmektedir. Üçüncü ve belki de en kritik boşluk, kural öğrenme problemidir. PHA etiketi, tanım gereği mutlak parlaklık (H) ve MOID gibi belirli eşik kuralları üzerinden türetilmektedir; ancak bu değişkenler eğitim kümelerinde aynen kullanıldığında, model gerçek anlamda yeni bir örüntü öğrenmek yerine mevcut etiketleme kuralını tersine mühendislikle yeniden öğrenmektedir. Bu durum, literatürde sıkça karşılaşılan %99 düzeyindeki doğruluk değerlerinin neden gerçek bir genellemeyi yansıtmadığını açıklamakta ve alanda metodolojik bir özdenetim eksikliğine işaret etmektedir.

Bu üç boşluğun birlikte değerlendirilmesi, tehlikeli asteroid sınıflandırması alanının yalnızca daha güçlü modellere değil; aynı zamanda risk-duyarlı metriklerle yapılandırılmış, sızıntı denetimi gözetilen ve dengesizlik müdahalesini şeffaf biçimde raporlayan bir metodolojik çerçeveye ihtiyaç duyduğunu ortaya koymaktadır. Bu çalışma, söz konusu üç boşluğu doğrudan hedef alarak literatüre konumlanmakta; başarı tanımını recall ve False Negative odaklı bir kompozit kritere taşımakta, sızıntı taşıyıcı değişkenleri kontrollü bir karşılaştırma çerçevesinde ele almakta ve dengesizlik müdahalesini yalnızca eğitim kümesine sınırlandıran bir protokol benimsemektedir.

3. Yöntem

Önerilen yöntem; veri ön işleme, özellik seçimi, model kurulumu, eğitim stratejisi ve risk-duyarlı değerlendirme olmak üzere beş aşamalı bir mimaride yapılandırılmıştır. Veri ön işleme aşamasında, modelleme açısından bilgi taşımayan ya da yanıltıcı sinyal üretebilecek sütunlar veri kümesinden çıkarılmıştır. Neo Reference ID ve Name gibi kimliğe özgü tanımlayıcılar, modelin örüntü öğrenmek yerine kayda ezberlemesini önlemek amacıyla elenmiştir. Orbiting Body ve Equinox gibi tek değerli sabit sütunlar varyans taşımadıkları için modelleme dışında bırakılmış ; tarih alanları ise doğrudan kullanıldığında yapay zamansal örüntüler üretebileceğinden kapsam dışında tutulmuştur. Aynı niceliğin farklı birimlerde tekrarlandığı sütun grupları (kilometre/mil/feet, km/s-km/sa-mpg, AU/km/mil/lunar) için yalnızca bir referans birim korunarak çoklu doğrusallığın azaltılması ve modelin gereksiz korelasyon yapılarına karşı kararlılığının artırılması hedeflenmiştir.

Özellik seçimi sürecindeki kritik karar, PHA tanımına çok yakın olan Minimum Orbit Intersection ve Absolute Magnitude değişkenlerinin nasıl ele alınacağı olmuştur. Bu değişkenler, etiketin türetildiği kuralın doğrudan girdileri olduğundan, eğitim kümesine aynen dâhil edildiklerinde modelin gerçek bir genelleme yerine etiketleme kuralını yeniden öğrenmesine yol açabilmektedir. Bu durumun denetlenmesi için iki kontrollü senaryo tasarlanmıştır: birinci senaryoda tüm öznelilikler kullanılarak literatürdeki yüksek başarıların kaynağı incelenmiş; ikinci senaryoda söz konusu sızıntı taşıyıcı değişkenler dışlanarak modelin yörünge dinamiklerini gerçek anlamda öğrenip öğrenemediği test edilmiştir. Bu ikili tasarımın, çalışmanın metodolojik geçerliliğinin temel taşı olması öngörülmüştür.

Veri, %80 eğitim ve %20 test olarak rastgele bölünmüş; sınıf oranlarının korunması için stratified split uygulanmıştır. Aynı asteroide ait tekrar gözlemlerin eğitim ve test kümelerine birlikte düşmesi durumunda ortaya çıkacak veri sızıntısını önlemek amacıyla bölünme, asteroid kimliğine duyarlı biçimde

gerçekleştirilmiştir. Sınıf dengesizliğine yönelik müdahale yalnızca eğitim kümesine uygulanmış; test kümesi, gerçek dünya dağılımını yansıtmayı için orijinal dengesiz formunda korunmuştur. Bu kapsamda iki tamamlayıcı strateji karşılaştırmalı olarak değerlendirilmiştir: azınlık sınıfı için sentetik örnek üreten SMOTE ve modelin kayıp fonksiyonunu sınıf frekansına göre yeniden ağırlıklandıran `class_weight='balanced'` mekanizması. İki yaklaşımın recall ve F1-skoru üzerindeki etkisi, problemin risk-duyarlı doğasıyla uyumlu biçimde analiz edilmiştir.

Model katmanı üç kademeli bir hiyerarşi üzerine kurulmuştur. İlk kademede Lojistik Regresyon, doğrusal bir referans noktası sunarak daha karmaşık modellerin sağladığı kazancın anlamlı olup olmadığını ölçmek üzere baseline olarak kullanılmıştır. İkinci kademede Random Forest tercih edilmiştir; bu modelin asteroid parametreleri arasındaki doğrusal olmayan etkileşimleri yakalama, aykırı değerlere dayanıklılık ve özellik ölçeklemesinden bağımsız çalışma özellikleri, problemin doğasıyla doğrudan uyumlu görülmüştür. Üçüncü kademede gradyan artırma prensibiyle çalışan XGBoost konumlandırılmıştır; modelin tablosal verilerde literatürde tutarlı biçimde üst düzey performans sergilemesi, düzenleme yetenekleri ve sınıf dengesizliğine yönelik `scale_pos_weight` parametresi sayesinde risk-duyarlı modelleme için elverişli bir çerçeve sunması, bu seçimi belirleyici kılmıştır. Bu üç modelin birlikte; doğrusal-doğrusal olmayan kapsama ile tek karar ağacından topluluk tabanlı boosting'e uzanan metodolojik bir yelpaze tanımlaması ve karşılaştırmaların bilimsel geçerliliğini güçlendirmesi hedeflenmiştir.

Eğitim sürecinde modellerin kararlılığı, beş katlı stratified k-fold çapraz doğrulama ile değerlendirilmiştir. Stratifikasyonun korunması, dengesiz veri koşullarında her katmanda azınlık sınıfının yeterince temsil edilmesini güvence altına almıştır. Hiperparametre ayarı GridSearchCV ile gerçekleştirilmiş; Random Forest tarafında ağaç sayısı (`n_estimators`), maksimum derinlik (`max_depth`), minimum bölünme örneği (`min_samples_split`) ve özellik alt kümesi (`max_features`) parametreleri taranmıştır. XGBoost için öğrenme oranı (`learning_rate`), ağaç derinliği (`max_depth`), alt örnekleme oranı (`subsample`), sütun örnekleme oranı (`colsample_bytree`) ve `scale_pos_weight` parametreleri optimize edilmiştir. Optimizasyon hedefi, doğruluk yerine F1-skoru ve recall'dan oluşan bileşik bir kriter olarak tanımlanmış; böylece arama sürecinin, çoğunluk sınıfına yanlı çözümler yerine pozitif sınıfı koruyan yapılandırmalara yönlendirilmesi hedeflenmiştir.

Değerlendirme aşaması, problemin risk-duyarlı doğasıyla uyumlu çok katmanlı bir metrik kümesi üzerine inşa edilmiştir. Birincil metrik olarak recall benimsenmiştir; bu seçim, gerçek bir tehlikeli

asteroidin gözden kaçırılmasının en yüksek maliyetli hata türü olduğu öncülüne dayanmaktadır. F1-skoru, recall ile precision arasındaki dengeyi izlenmesini sağlayarak modelin aşırı agresif pozitif tahminler üretmesini engelleyen bir denge ölçütü olarak raporlanmıştır. Sınıflandırıcının ayırt edicilik kapasitesini eşik değerinden bağımsız değerlendirmek üzere ROC-AUC hesaplanmıştır; ancak dengesiz veri koşullarında ROC eğrisinin iyimser sonuçlar üretebileceği bilindiğinden, azınlık sınıfının gerçek başarımlarını daha sadık biçimde yansıtan PR-AUC tamamlayıcı metrik olarak eklenmiştir. Tüm modeller için karışıklık matrisinin üretilmesi ve özellikle False Negative sayısının, modeller arası nihai karar kriteri olarak konumlandırılması öngörülmüştür. Bu çok katmanlı çerçevenin, çalışmanın yalnızca yüksek skor üreten değil, aynı zamanda gerçek anlamda güvenli sınıflandırma sağlayan bir model seçimini mümkün kılması hedeflenmiştir.

3.1. Operasyonel Karar Destek Sistemi Prototipi

Araştırma kapsamında geliştirilen makine öğrenmesi modelinin teorik bir çıktı olmanın ötesine geçerek, gezegen savunma mekanizmalarında gerçek zamanlı bir karar destek sistemi olarak kullanılabilirliğini kanıtlamak adına bir operasyonel prototip geliştirilmiştir. Bu doğrultuda, sızıntısız veri kümesi üzerinde en yüksek Recall ve F1-skorumu sunan XGBoost algoritması, Joblib kütüphanesi kullanılarak serialize edilmiş ve model mimarisi olarak kaydedilmiştir. Kaydedilen model nesnesi, Python tabanlı hafif bir mikro-çerçeve mimarisine entegre edilerek bir web arayüzü üzerinden erişime açılmıştır. Sistem, bir astronominin teleskop gözlemlerinden elde ettiği 20 temel yörünge parametresini dinamik girdi olarak kabul etmekte; arka planda bu verileri eğitim sürecindeki StandardScaler matrisi ile ölçeklendirerek eğitilmiş XGBoost modeline iletmektedir. Model, milisaniyeler düzeyinde bir çıkarım gerçekleştirerek cismin potansiyel tehlike durumunu ikili sınıf etiketinin yanı sıra bir risk olasılık yüzdesi (`predict_proba`) olarak son kullanıcıya sunmaktadır. Geliştirilen bu arayüz, makine öğrenmesi teorisinin gerçek dünya mühendislik çözümlerine dönüşebileceğinin somut bir kanıtı olarak kurgulanmış ve araştırmacıların kullanımına açık bir web servisi olarak canlıya alınmıştır (Erişim Adresi: <https://asteroid-hazard.streamlit.app/>).

4. Bulgular

Bu bölümde, NASA Jet Propulsion Laboratory (JPL) kaynaklı veri kümesi üzerinde yürütülen deneysel simülasyonların sayısal çıktıları detaylandırılmıştır. Sınıflandırma performansları değerlendirilirken salt doğruluk kriterinin yarattığı istatistiksel illüzyon aşılmış; gezegen savunması operasyonel gereksinimleri doğrultusunda pozitif sınıfı (Sınıf 1: Tehlikeli) koruma

kapasitesi öne çıkarılmıştır. Bu doğrultuda modeller, test kümesinde yer alan toplam 938 gözlem (787 adet tehlikesiz, 151 adet tehlikeli asteroit) üzerinden simüle edilerek test edilmiştir.

4.1. Tablolar

Modelleme katmanında elde edilen makro ve mikro metriklerin karşılaştırmalı analizi, modellerin operasyonel sınır koşulları ekseninde Tablo 1 ve Tablo 2'de ayrıntılandırılmıştır.

Tablo 1. Makine Öğrenmesi Modellerinin Performans Karşılaştırması (Tehlikeli Sınıf - 1)

Model Türü	Senaryo	Precision	Recall	F1-Score	Accuracy
Random Forest	Sızıntılı	0.99	0.99	0.99	1.00
Lojistik Regresyon	Temiz	0.35	0.79	0.48	0.73
Random Forest	Temiz	0.72	0.84	0.77	0.92
XGBoost	Temiz	0.80	0.86	0.83	0.94

Sınıflandırma yeteneklerinin yanı sıra, modellerin sınıf dengesizliği altındaki ayırt edicilik kapasitelerini eşikten bağımsız olarak ölçen olasılıksal metrikler (ROC-AUC ve PR-AUC) ve operasyonel güvenliğin temel göstergesi olan False Negative sayıları Tablo 2'de sunulmuştur.


Tablo 2. Modellerin Olasılıksal Ayırt Edicilik ve False Negative Analizi

Model Türü	Senaryo	ROC-AUC	PR-AUC	False Negative
Random Forest	Sızıntılı	1.00	1.00	1
Lojistik Regresyon	Temiz	0.82	0.45	32
Random Forest	Temiz	0.97	0.86	24
XGBoost	Temiz	0.98	0.90	21


Tablolar yakından incelendiğinde, veri seti durumu ve model türüne bağlı olarak başarımların radikal bir biçimde değiştiği gözlemlenmektedir. Literatürde sıklıkla karşılaşılan ve yapısal hedef sızıntısı barındıran veri durumuyla eğitilen model, %100'e yakın yapay skorlar sergilemiştir. Sızıntı unsurları arındırıldığında ise modellerin gerçek öğrenme kapasiteleri ortaya çıkmıştır. Doğrusal bir model olan Lojistik Regresyon, yüksek oranda yanlış alarm üreterek 0.35 precision değerinde kalmış ve PR-AUC değeri açısından zayıf bir performans göstermiştir. Temiz veri koşullarında en yüksek performansı sergileyen XGBoost algoritması

ise; 0.976 ROC-AUC ve 0.896 PR-AUC ayırt edicilik skorlarına ulaşmış ve en tehlikeli hata türü olan False Negative sayısını 21'e (toplam 151 PHA test örneği içinde) indirgeyerek projenin en kararlı ve risk-duyarlı modeli olmuştur.


4.2. Şekiller



Şekil 1. Lojistik Regresyon (Baseline) Modeli Karışıklık Matrisi




Şekil 2. Random Forest Modeli Karışıklık Matrisi




Şekil 3. XGBoost Modeli Karışıklık Matrisi

Modellerin operasyonel güvenilirliğini ve hata dağılımlarını nicelleştirmek adına üretilen karışıklık matrisleri Şekil 1, Şekil 2 ve Şekil 3'te ayrı ayrı sunulmuştur. Şekillerdeki veri matrisleri incelendiğinde, projenin birincil optimizasyon hedefi olan False Negative sayısındaki değişim net bir biçimde izlenebilmektedir. Toplam 151 tehlikeli asteroit test örneği içinde; Lojistik Regresyon baseline modeli (Şekil 1) 32 cismi gözden kaçırmış, Random Forest (Şekil 2) bu sayıyı 24'e düşürmüştü, XGBoost (Şekil 3) ise gradyan artırma optimizasyon gücü sayesinde False Negative sayısını 21'e indirgeyerek en yüksek operasyonel emniyet sınırını yakalamıştır.




Şekil 4. Temizlenmiş Veri Seti Üzerinde Modellerin ROC Eğrisi Karşılaştırması



Şekil 5. Temizlenmiş Veri Seti Üzerinde Modellerin Precision-Recall (PR) Eğrisi Karşılaştırması

Şekil 4 ve Şekil 5'te sunulan eğriler, sınıf dengesizliği altında modellerin ayırt edicilik kapasitelerini eşikten bağımsız olarak görselleştirmektedir. Yöntem bölümünde öngörüldüğü üzere, ROC eğrisi azınlık sınıfındaki zafiyetleri maskeleyerek tüm modeller için nispeten iyimser bir tablo çizerken; asıl operasyonel performansı yansıtan PR eğrisinde modellerin gerçek güçleri ayrılmıştır. Doğrusal Lojistik Regresyon modeli PR düzleminde yapısal bir çöküş yaşarken, XGBoost algoritması yüksek recall seviyelerinde bile precision rakiplerine kıyasla çok daha güçlü bir şekilde koruyarak dengesiz veri koşullarındaki üstünlüğünü kanıtlamıştır.



Şekil 6. Temizlenmiş Veri Kümesinde XGBoost Algoritmasının Öznitelik Önemi (Feature Importance) Dağılımı

Şekil 6'da, PHA tanımının doğrudan girdileri olan sızıntı değişkenleri dışlandıktan sonra, XGBoost modelinin tehlike durumunu tahmin ederken hangi dolaylı yörünge mekaniklerine ağırlık verdiği gösterilmiştir. Modelin, kural ezberlemek yerine yörünge eğikliği (inclination), yörünge dışmerkezliği

(eccentricity) ve yarı büyük eksen gibi karmaşık astrofiziksel parametreler arasındaki doğrusal olmayan korelasyonları deşifre ederek karara ulaştığı somutlaştırılmıştır.

5. Tartışma

Bu çalışmada elde edilen sayısal sonuçlar, tehlikeli asteroit sınıflandırması alanında epistemolojik bir özdenetim ihtiyacını açıkça ortaya koymaktadır. Literatür taraması kapsamında incelenen ve %99 seviyesinde doğruluk raporlayan klasik çalışmaların büyük kısmının, aslında veriye gömülü deterministik kuralları tersine mühendislikle yeniden ürettiği deneysel olarak doğrulanmıştır. Bu sızıntı unsurları veri kümesinden elimine edildiğinde, problemin gerçek zorluk derecesi ortaya çıkmaktadır.

Doğrusal modellerin tabular yörünge uzayındaki yetersizliği, Lojistik Regresyon'un 0.35 precision değerinde kalmasıyla somutlaşmıştır. Bu durum, yörünge elemanlarının uzaydaki kütleçekimsel etkileşimlerinin doğrusal sınırlarla ayıramayacağını göstermektedir. SMOTE sentetik aşırı örnekleme metodolojisinin yalnızca eğitim kümesine izole edilmesi, test kümesinin ise orijinal dengesiz formunda korunması, raporlanan %86'lık recall başarısının aşırı iyimser bir yanılgı barındırmadığını, tamamen gerçek dünya dağılımlarını yansıttığını metodolojik olarak kanıtlamaktadır. XGBoost algoritmasının Random Forest'a kıyasla hem kesinlik hem de duyarlılık ekseninde daha üstün performans göstermesi, gradyan inişi tabanlı sıralı öğrenme mekanizmasının, sızıntı unsurları arındırılmış zorlayıcı veri sınırlarında daha esnek karar yapıları inşa edebilmesinden kaynaklanmaktadır.

6. Sonuçlar

Bu araştırma kapsamında, NASA NeoWs veri seti üzerinde sınıf dengesizliği ve hedef sızıntısı kısıtları altında risk-duyarlı bir yapay zekâ çerçevesi başarıyla kurgulanmıştır. Geliştirilen sızıntı denetimli XGBoost modeli, doğrudan ayırt edici iki temel parametre (Absolute Magnitude ve MOID) olmadan da, asteroitlerin dolaylı yörünge dinamiklerini analiz ederek %86 duyarlılık oranıyla gezegen savunma sistemlerine entegre edilebileceğini ortaya koymuştur. Bu yönüyle çalışma, saf bir veri madenciliği uygulamasının ötesine geçerek alan bilgisi ile veri biliminin sentezlendiği metodolojik bir rehber niteliğindedir.

Mevcut literatürdeki kaynakların büyük bir kısmı veri setindeki tüm öznitelikleri kontrolsüz biçimde eğitime dâhil ederek yüksek fakat operasyonel geçerliliği olmayan başarılar üretirken; bu projede yapısal "hedef sızıntısı" problemi ilk kez izole edilmiş ve ortadan kaldırılmıştır. Modelin, doğrudan kopya çeken değişkenler olmadan da tehlikeli asteroitleri yüksek bir

başarıyla sınıflandırabileceği kanıtlanarak literatürdeki önemli bir metodolojik boşluk kapatılmıştır.

NOT: Bu proje çalışması ve ilgili veri seti analizleri yalnızca bu ders kapsamında gerçekleştirilmiş olup, geçmişte veya gelecekte başka herhangi bir derste proje olarak kullanılmamıştır ve kullanılması düşünülmemektedir.

Teşekkür

Bu çalışmanın açık erişimli veri altyapısını sağlayan NASA Jet Propulsion Laboratory (JPL) veri analitiği ekiplerine ve Kaggle platformuna akademik katkılarından dolayı teşekkür ederiz.

Araştırmacıların Katkısı

Bu araştırmada; Muhammed Mehmet Gökçe, veri temizleme protokollerinin tasarlanması, hedef sızıntısı senaryolarının kurgulanması, Python tabanlı makine öğrenmesi algoritmalarının implementasyonu, model değerlendirme süreçlerinin yürütülmesi ve operasyonel karar destek sistemi prototipinin geliştirilmesi; Alperan Uzuner, uluslararası veritabanları üzerinden sistematik literatür taramasının gerçekleştirilmesi ve makale formatındaki "Giriş" ile "Yazın Taraması" bölümlerinin akademik dille oluşturulması; Ali Yılmaz ise astronomik parametrelerin fiziksel anlamlarının çözümlenmesi, tabloların düzenlenmesi ve bulguların analitik raporlanması süreçlerinde eşit oranda katkı sağlamışlardır.

Çıkar Çatışması

Yazarlar tarafından herhangi bir çıkar çatışması beyan edilmemiştir.

Kaynaklar

NASA Jet Propulsion Laboratory. (2026). Center for Near Earth Object Studies (CNEOS). Erişim adresi: <https://cneos.jpl.nasa.gov/>

Nandika P. S. vd., "Comparative Analysis of Machine Learning Models for Hazardous Asteroid Classification", INCOFT 2025, 2025. Erişim Adresi: <https://www.scitepress.org/Papers/2025/135994/135994.pdf>

Bora, C. A., "Temporal trends in asteroid behaviour: a machine learning and N-body integration approach", Monthly Notices of the Royal Astronomical Society (MNRAS), 2024. Erişim Adresi: <https://academic.oup.com/mnras/article/534/1/415/7750043>

Al Mamun, A. M. vd., "Near-earth asteroids classification using NGBoost classifier", Material Science & Engineering International Journal, 2024. Erişim Adresi: <https://medcraveonline.com/MSEIJ/MSEIJ-08-00231.pdf>

Bhavsar, R. vd., "Classification of Potentially Hazardous Asteroids Using Supervised Quantum Machine Learning", IEEE Access, 2023. Erişim Adresi: <https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=10188662>

Malakouti, S. M. vd., "Machine learning techniques for classifying dangerous asteroids", MethodsX, 2023. Erişim Adresi: https://www.researchgate.net/publication/373250818_Machine_Learning_Techniques_for_Classifying_Dangerous_Asteroids

MDPI Araştırmacıları, "Assessment of asteroid classification using deep convolutional neural networks", Aerospace, 2023. Erişim Adresi: <https://www.mdpi.com/2226-4310/10/9/752>

NASA Jet Propulsion Laboratory. (2023). NASA: Asteroids classification dataset [Veri kümesi]. Kaggle. Erişim adresi: <https://www.kaggle.com/datasets/shrutimehta/nasa-asteroids-classification>

NHSJS Araştırmacıları, "Classifying Hazardous and Non-Hazardous Asteroids Using Machine Learning", The National High School Journal of Science, 2022. Erişim Adresi: https://nhsjs.com/wp-content/uploads/2022/12/Classifying_Hazardous_and_Non_Hazardous_Asteroids_Using_Machine_Learning-2.pdf

Kadkhodaei, H. vd., "Big data classification using heterogeneous ensemble classifiers in Apache Spark based on MapReduce", Expert Systems with Applications, 2021. Erişim Adresi: https://www.researchgate.net/publication/352319722_Big_data_classification_using_heterogeneous_ensemble_classifiers_in_Apache_Spark_based_on_MapReduce_paradigm